

Identificacao de escassez de equipamentos em redes de saude: um estudo de caso utilizando dados do CNES no Brazil

Pedro H. Prestes, Alexandre C. B. Delbem, Eric K. Tokuda

September 2025

1 Cronograma

Período	Atividades
15/dez – 31/dez	Análise das fontes de dados do CNES - Comparar FTP x Website x API
31/dez – 05/jan	Coleta dos dados amostral
05/jan – 01/mar	Pré-processamento dos dados - Filtragem de tabelas (consultar dic de dados) - Estatísticas da nossa amostra
01/mar – 15/mar	Modelagem ML clássico - Tarefa: (1) predição de número de leitos; outros - Modelo geral - Modelo geral com apenas o último snapshot - Modelo por entidade
15/mar – 15/abr	Modelagem de RDL - Utilizar a mesma tarefa
15/abr – 20/abr	Coleta de uma amostra maior de dados - Consultar especialistas sobre o interesse - Considerar limitações computacionais e de tempo
20/abr – 31/mai	Fluxo completo sobre a nova amostra - Considerar código minimamente otimizado - Executar em algum cluster
31/mai – 15/jun	Análise dos dados
15/jun – 31/jul	Finalização da escrita e submissão de artigo

1.1 Análise das fontes de dados do CNES

Após uma análise minuciosa das diferentes formas de obter dados do Cadastro Nacional de Estabelecimentos de Saúde, o meio que mais se adequa aos objetivos dessa pesquisa é o banco de produção federal disponibilizado no site

do CNES. A escolha pelo banco de produção federal, justifica-se pela sua integridade técnica e pela natureza relacional de sua estrutura, que permite uma análise multidimensional exaustiva da rede de saúde. Diferente de interfaces como o TABNET ou a API ElastiCNES, que muitas vezes entregam dados pré-processados, agregados ou recortes específicos, o banco original oferece o conjunto integral de microdados brutos em sua forma mais granular. Essa distinção é fundamental para o rigor científico, uma vez que é extremamente difícil verificar a real completude e fidedignidade dos dados obtidos por outras fontes em relação ao banco de produção, dado que ferramentas intermediárias podem aplicar filtros, simplificações ou sofrer com atrasos de sincronização que não são totalmente transparentes ao pesquisador. Assim, ao optar pela fonte primária, a pesquisa assegura o acesso à totalidade das variáveis e a possibilidade de realizar cruzamentos complexos sem as limitações ou incertezas impostas por camadas externas de extração.

1.2 Coleta de dados amostral

Os dados utilizados serão os de estabelecimentos da capital paulista nas snapshots de 01/2017, 01/2019, 01/2021, 01/2023, 01/2025.

1.3 Pré-processamento dos dados

No pré-processamento, as tabelas foram analisadas individualmente para a seleção de variáveis críticas à análise preditiva. Priorizaram-se atributos com alta taxa de preenchimento, alta variância e natureza numérica ou categórica dos dados.

1.4 Ideias de modelagem de modelos preditivos

1. Relbench: A ideia é que, com os dados limpos, pegamos um conjunto de vários meses da base de dados do CNES e integramos de modo que cada conjunto do tipo mês-ano possa representar um timestamp e somente serão utilizadas linhas que sofreram algum tipo de alteração, pois somente essas são úteis para o modelo. (Ver se as alterações são relevantes ao longo do tempo é uma tarefa inclusa na avaliação de completude). Após isso, jogar os dados de acordo com o padrão do framework.
2. Modelagem direta: Criar nossa própria modelagem dos dados independente da estrutura de tabelas e aplicar um modelo de GNNs, uma ideia é usar os estabelecimentos como nós e as arestas como representações da proximidade geográfica. Nesse caso, podemos utilizar dados já agregados e limpos do PCDaS da Fiocruz em <https://pcdas.iciet.fiocruz.br/conjunto-de-dados/cadastro-nacional-de-estabelecimentos-de-saude/> para pelo menos iniciar esse processo.